

Kritische KI-Nutzung

Generative KI, Bots und Agenten
im reflektierten Einsatz

Tobias Hodel
Digital Humanities / Walter Benjamin Kolleg
Workshop AG Interne Weiterbildung
UniS A-124 · 14. Oktober 2026



dhbern.github.io/kritische-ki-nutzung

Ablauf


14. Oktober 2026, 13:00–17:00

13:00	Begrüssung
13:05	Vorstellungsrunde
13:25	Einstieg: Swiss History Bot testen
13:40	Input: Generative KI – Stand von Technologie und Anwendung
14:35	Toolübersicht, KI-Angebote der Uni Bern, GPUStack
14:50	Pause (inkl. Zeit für Fragen, WLAN, Logins)
15:05	Aufgaben in Gruppen
16:05	Präsentation und Auswertung
16:35	Agentische Systeme: Agentic Historian
16:50	Strategien, Fragen, Evaluation

Vorstellungsrunde

13:05–13:25

- Name und Arbeitsbereich
- Wo begegnen dir grosse Bild- oder Textmengen im Arbeitsalltag?
- Welche KI-Werkzeuge nutzt du bereits – wofür?
- Was möchtest du heute mitnehmen?



Swiss History Bot: semantische Suche

The screenshot shows the Swiss History Bot interface. At the top, it says 'Swiss History Bot' and 'ALPHA - PROTOTYPE'. Below the navigation bar, the page is titled 'Semantische Suche'. A search bar contains the text 'Niederrohrdorf im 17. Jahrhundert'. Below the search bar, there is a list of search results. The first result is '1. Bernard Degen: Niederdorf, in: HLS/DHS'. The second result is '2. Waltraud Hörsch: Neudorf, in: HLS/DHS'. The third result is '3. Christian Lüthi: Rothrist, in: HLS/DHS'. The fourth result is '4. Patrick Zehnder: Rothrist, in: HLS/DHS'. Each result has a brief description and a link to the full text.

- Sucht nach Bedeutung, nicht nach Wortlaut
- Bestände: HLS, HBLS, e-periodica, Königsfelden, HGB Basel, SSRQ, Dodis, StAZH, infoclio, BSG
- Treffer getrennt nach Quellen und Literatur

Beispiel: «Niederrohrdorf im 17. Jh.» liefert
Niederdorf, Neudorf, Rothrist ...

Ausprobieren:

Swiss History Bot testen (13:25–13:40)

1 • Dialog

Stelle eine Frage zu einem Thema, das du gut kennst.

Öffne zwei Fussnoten: Steht dort, was die Antwort behauptet?

2 • Suche

Suche einen Ort oder eine Person mit Zeitraum.

Wie viele Treffer passen wirklich?
Wo führt «Ähnlichkeit» in die Irre?

3 • Grenzen

Frage nach etwas, das kaum belegt ist.

Sagt der Bot «weiss ich nicht» – oder erfindet er?
Stimmen die Personen-Links?

Zugang in der Sitzung • Beobachtungen notieren – wir kommen im Input und am Schluss darauf zurück

Was kennst du schon?


Stichworte zum Input

- Multimedialität / Multimodalität
- Reasoning
- Softwaretools (Cursor, Codex, Claude Code)
- GPUStack
- Bots und Agents
- Mixture of Experts
- OpenClaw (ClawdBot)
- Hugging Face


Themen

- Wie Sprachmodelle funktionieren – und wo sie scheitern
- Was ist neu? Multimodalität, Reasoning, Mixture of Experts
- Anwendungen: Extraktion, RAG, «Data Science», Linked Open Data
- Werkzeuge und KI-Angebote der Uni Bern (GPUStack)
- Aufgaben in Gruppen und Präsentation
- Agentische Systeme
- Strategien für einen reflektierten Umgang

Vector Space



Representation as mathematical function/neural network



Quelle: Rico Sennrich, Interaktive Sprachmodelle: Ein Blick hinter die Kulissen.

https://kilof.unibe.ch/veranstaltungen/vergangene_veranstaltungen/kilof_tagung/index_ger.html

Probleme

(optimiert auf *Textgenerierung* ...)

- Halluzinationen
 - Seltenes «Wissen» ist schlecht repräsentiert
- Bias
 - Spiegelt das Trainingsmaterial (rassistisch, sexistisch, ableistisch, ...)
 - auch wenn Nachtraining (Reinforcement) dies abzufedern versucht
- Kein oder wenig Trainingsmaterial, z. B. für historische Texte

Anwendungsszenarien (bereits „old fashioned“)

Kreative Ansätze:

- Umformulieren
- Zusammenfassen
- Informationsextraktion
- Programmcode erzeugen

→ mit Vorsicht einsetzen!

Sprachmodelle unterstützen bei der Erschliessung

Extraktion von

- Named Entities (NER)
- Topics (ähnlich Topic Modeling)
- Schlagworten
- Übersetzung und Normalisierung
- Korrektur erkannter Texte

→ mit Vorsicht einsetzen!

Halluzinationen reduzieren: eigene RAGs (NotebookLM) In der Blackbox von OpenAI/Google/...

 Course_Bot_NLP-2024

 Freigeben  Einstellungen 

Quellen

 Build a Local RAG Application |  LangChain

 GMT20240917-120938_Recording.transcript.txt

 How to load documents from a directory |  ...

 Khurana_Intro_NLP.pdf

 NLP for the Humanities – DH Kolloquium HS2024

 On the Dangers of Stochastic Parrots | Proceed...

 Run models locally |  LangChain

 Text Analysis in Python for Social Scientists

 Tutorial 2: Training models | flair

Chat

Aktualisieren

Based on Jurafsky define Sentiment Analysis

Die Sentimentanalyse ist ein Teilbereich der NLP, der sich mit der **automatischen Identifizierung und Klassifizierung von Emotionen und Meinungen in Textdaten** befasst. 1. Es wird verwendet, um die subjektive Information in einem Text zu verstehen, wie z. B. ob der Autor einen positiven, negativen oder neutralen Standpunkt zu einem bestimmten Thema vertritt. 1 Sentimentanalyse umfasst typischerweise Aufgaben wie:

- **Polaritätsklassifizierung:** Bestimmen, ob ein Text eine positive, negative oder neutrale Stimmung ausdrückt. 1
- **Emotionserkennung:** Identifizieren spezifischer Emotionen, die in einem Text ausgedrückt werden, wie z. B. Freude, Traurigkeit, Wut oder Angst. 1 ...
- **Intensitätsanalyse:** Messen der Stärke oder des Grades der ausgedrückten Stimmung oder Emotion. 1 ...

Anwendungen der Sentimentanalyse:

Studio > Notiz

Natürliche Sprachverarbeitung: Studienleitfaden

(Gespeicherte Antworten können nicht bearbeitet werden)

Studienleitfaden für die Verarbeitung natürlicher Sprache Quiz

Beantworten Sie die folgenden Fragen in 2-3 Sätzen.

1. Was ist der Unterschied zwischen Tokenisierung und Satzteilung?
2. Definieren Sie die Begriffe "Typ" und "Token" im Kontext der Textanalyse.
3. Erläutern Sie die Bedeutung von n-Grammen in der Sprachmodellierung.
4. Was ist der Zweck der Punktweise Mutual Information (PMI)?
5. Beschreiben Sie den Unterschied zwischen diskreten und verteilten Repräsentationen von Text.
6. Was ist der Hauptvorteil der Singular Value Decomposition (SVD) in der Textanalyse?
7. Wie visualisiert man Dokumentembeddings?
8. Was ist die Markov-Annahme in Sprachmodellen?
9. Erklären Sie den Begriff "Smoothing" im Kontext von Sprachmodellen.
10. Worin unterscheiden sich Themenmodelle von Clustering-Algorithmen?

Quizantworten

1. **Tokenisierung** trennt einen Text in einzelne Wörter und Satzzeichen, während **Satzteilung** einen Text in Sätze zerlegt.
2. Ein **Typ** bezieht sich auf ein einzigartiges Wort in einem Text. Ein **Token** ist jede Instanz



Quellen



Chat

Aktualisieren

Bui

GM

Hov

Khurana_Intro_NLP.pdf

NLP for the Humanities – DH Kolloquium HS2024

On the Dangers of Stochastic Parrots | Proceed...

Run models locally | LangChain

Text Analysis in Python for Social Scientists

Tutorial 2: Training models | flair

Tutorial 3: Embeddings | flair

<https://web.stanford.edu/~jurafsky/slp3/17.pdf><https://web.stanford.edu/~jurafsky/slp3/3.pdf><https://web.stanford.edu/~jurafsky/slp3/6.pdf><https://web.stanford.edu/~jurafsky/slp3/9.pdf>

Analysis

Halluzinationen reduzieren: NotebookLM

automatischen Identifizierung und Klassifizierung von Emotionen und Meinungen in Textdaten fasst 1. Es wird verwendet, um die subjektive Information in einem Text zu verstehen, wie z. B. ob der Autor einen positiven, negativen oder neutralen Standpunkt zu einem bestimmten Thema vertritt. 1 Sentimentanalyse umfasst typischerweise Aufgaben wie:

- **Polaritätsklassifizierung:** Bestimmen, ob ein Text eine positive, negative oder neutrale Stimmung ausdrückt. 1
- **Emotionserkennung:** Identifizieren spezifischer Emotionen, die in einem Text ausgedrückt werden, wie z. B. Freude, Traurigkeit, Wut oder Angst. 1 ...
- **Intensitätsanalyse:** Messen der Stärke oder des Grades der ausgedrückten Stimmung oder Emotion. 1 ...

Anwendungen der Sentimentanalyse:

- **Social Media Monitoring:** Verfolgen Sie die öffentliche Meinung zu Marken, Produkten oder politischen Kandidaten. 1
- **Kundenfeedback-Analyse:** Verstehen Sie, wie Kunden über Produkte und Dienstleistungen denken. 1
- **Marktforschung:** Identifizieren Sie Trends und Muster in Verbraucherpräferenzen. 1

Text eingeben...



14 Quellen



Wie wird Sentimentanalyse im Kontext der Hexenprozess-Analyse einge...



Studio > Notiz



Natürliche Sprachverarbeitung: Studienleitfaden



(Gespeicherte Antworten können nicht bearbeitet werden)

Studienleitfaden für die Verarbeitung natürlicher Sprache Quiz

Beantworten Sie die folgenden Fragen in 2-3 Sätzen.

1. Was ist der Unterschied zwischen Tokenisierung und Satzteilung?
2. Definieren Sie die Begriffe "Typ" und "Token" im Kontext der Textanalyse.
3. Erläutern Sie die Bedeutung von n-Grammen in der Sprachmodellierung.
4. Was ist der Zweck der Punktweise Mutual Information (PMI)?
5. Beschreiben Sie den Unterschied zwischen diskreten und verteilten Repräsentationen von Text.
6. Was ist der Hauptvorteil der Singular Value Decomposition (SVD) in der Textanalyse?
7. Wie visualisiert man Dokumentembeddings?
8. Was ist die Markov-Annahme in Sprachmodellen?
9. Erklären Sie den Begriff "Smoothing" im Kontext von Sprachmodellen.
10. Worin unterscheiden sich Themenmodelle von Clustering-Algorithmen?

Quizantworten

1. **Tokenisierung** trennt einen Text in einzelne Wörter und Satzzeichen, während **Satzteilung** einen Text in Sätze zerlegt.
2. Ein **Typ** bezieht sich auf ein einzigartiges Wort in einem Text. Ein **Token** ist jede Instanz eines Typs im Text. Beispiel: Der Satz "Der Hund jagt den Hund" hat 5 Token und 3 Typen.
3. **N-Gramme** sind Sequenzen von n Wörtern in einem Text. Sie werden in der Sprachmodellierung verwendet, um die Wahrscheinlichkeit des Auftretens eines Wortes basierend auf den vorhergehenden n-1 Wörtern zu schätzen.
4. **PMI** misst die statistische Abhängigkeit zwischen zwei Wörtern. Ein hoher PMI-Wert zeigt an, dass die beiden Wörter häufiger zusammen auftreten als zufällig erwartet.
5. **Diskrete Repräsentationen** verwenden eindeutige Indizes für jedes Wort im Vokabular, während **verteilte Repräsentationen** Wörter als Vektoren in einem kontinuierlichen Vektorraum darstellen.
6. **SVD** reduziert die Dimensionalität von Textdaten, indem die wichtigsten Informationen beibehalten werden. Dies vereinfacht die Analyse und Visualisierung großer Datensätze.

Als Quelle festlegen

Halluzinationen reduzieren:

Retrieval Augmented Generation (RAG)

- Ähnlich wie andere Lösungen – aber Open Source
- Embeddings für Texte/Textstücke erzeugen
- In einer Vektordatenbank speichern
- LLM generiert Text auf Basis der gefundenen Textstücke

```
service_context = servicecontext_from_documents(embedding_model=embedding_model, documents=documents)
```

What documents mention mills and what are the main issues, when mills are mentioned? Provide the literal context and enumerate the instances. Finally create a summary.

The context mentions several documents that refer to mills. Here are the main issues related to mills in these documents:

1. Königsf. 685: This document discusses a dispute between Hans Birkinger and the noble ladies of the monastery of Königsfeld regarding the lease of a mill. The main issue is the disagreement over the terms of the lease and the rights and obligations of both parties.
2. Königsf. 1001: This document is a sales contract for a mill and its associated properties in Lind. The main issue is the sale of the mill and the transfer of ownership to the buyer.
3. Königsf. 1002: This document is a copy of a sales contract for a mill and its associated properties in Lind. The main issue is the sale of the mill and the transfer of ownership to the buyer.
4. Königsf. 556: This document discusses the sale of a mill in Mülinen before it came into the possession of the current owners. The main issue is the sale of the mill and the transfer of ownership to the buyer.
5. Königsf. 557: This document is an old and useless receipt for a mill in Brugg. The main issue is the payment of a debt related to the mill.

From these documents, it appears that the main issues related to mills are disputes over leases, sales, and transfers of ownership. These issues often involve disagreements over the terms of the lease or sale, the rights and obligations of both parties, and the payment of debts related to the mill.

RAG im Einsatz:

FRAG – Chatbot für die Hochschuldidaktik

- Kontext = hochschuldidaktische Literatur
- Embeddings = nach Ähnlichkeit sortiert
- Die Anfrage wird in ein Embedding umgewandelt
- Ähnliche Textstücke werden dem LLM übergeben
- Das LLM formuliert «passgenauere» Antworten

Ohne Programmierung: NotebookLM – heute im Workshop ausprobieren

RAG im Einsatz:

Swiss History Bot

- Kontext = „Geschichte der Schweiz“ (HLS, e-Periodica, Dodis, ...)
- Embeddings = nach Ähnlichkeit sortiert
- Die Anfrage wird umformuliert und danach in ein Embedding umgewandelt
- Trennung von «Literatur» & «Quellen»
- Ausgabe von Links

Was ist neu?

Update 1: Reasoning & Multimodalität

Grössere Kontextfenster

Mehr Text, Bilder, ... werden auf einmal verarbeitet.

Reasoning

Keine direkte Ausgabe (next token), sondern interne Textgenerierung («chain of thought»), die erst in einem zweiten/dritten Schritt ausgegeben wird.

→ Prompting verliert an Gewicht, Ausgaben wirken besser angepasst.


Embedding von allem

Bilder, Töne, ... werden wie Texte als Embeddings im selben Vektorraum behandelt.

→ Eingaben in unterschiedlichen medialen Formen werden möglich.

Wir bleiben im latent space: abhängig vom Trainingsmaterial, biased, «mehrschichtiger und abgefedert».


Vom Sprachmodell zum multimodalen Modell



Quelle: <https://nlp4vis.github.io/>

Technologie-Update

Update 2: Mixture of Experts (MoE)



- Nicht mehr das ganze Netz ist aktiv
- «Spezialisierte Teilmodelle», definiert über die Anzahl Experts und das Trainingsmaterial
- Keine Fachexpertise (Biologie, Geschichte), sondern linguistisch abschliessbare Aufgaben (Gleichungen, Code)
- Effizienter – aber Trainingsmaterial (und Bias) bleibt

Konsequenz:

Schub für kleinere Modelle

- Modelle mit 1-40 Mrd. Parametern werden «fähiger»
 - Qwen 3.5 9B für Coding
 - Phi 14B für Mathematik
 - Gemma 4 31B

Konsequenzen

- Lokaler Betrieb wird mit bezahlbarer Infrastruktur möglich
- Open-Source-Modelle bleiben interessant → gpustack.unibe.ch

Wissensextraktion: vom LLM zu Linked Open Data

Knowledge Extraction: The Problematic


Corpus 1

Julius Cesar (12.07.100 BC; 15.03.44 BC) ...

Corpus 2

Julius Cesar was born on 12th July -100 and assassinated on 15th March -44 ...

Each corpus can have its way of saying the same things



Wissensextraktion: vom LLM zu Linked Open Data

Knowledge Extraction: The Idea

Corpus 1

Julius Cesar (12.07.100 BC; 15.03.44 BC) ...

Corpus 2

*Julius Cesar was born on 12th July -100
and assassinated on 15th March -44 ...*

Make a LLM reformulate raw informations into semi structured information (atomic assertions) and do some topic modeling

Atomic assertions

- Julius Cesar is born on 12.07.100 BC → birth
- Julius Cesar died on 15.03.44 BC → death
- ...

Classic NLP on individual assertions,
depending on assertion topic

Result examples

Part of the extracted graph


[illegible]

Result examples

Daniel Peter, from the HLS:

Daniel Peter naît le 9.3.1836 à Moudon, meurt le 4.11.1919 à Vevey, protestant, de Lavey-Morcles. Fils de Jean Samuel, maître boucher, et de Jeanne-Louise Laurent. Marié(e) (1863) à Fanny-Louise Cailler, fille de François-Louis Cailler (<https://hls-dhs-dss.ch/fr/articles/030578/2003-03-20/>). Apprentissage de commerce à Vevey, où Daniel Peter ouvrit en 1856 une fabrique et commerce de chandelles (Frères Peter). Il diversifia ensuite ses activités et s'occupa également de la fabrication de chocolat, en association avec son beau-père (Peter, Cailler et Cie dès 1867). Inventeur de la formule du chocolat au lait (1875). Conseiller municipal à Vevey (1893-1896). En 1896, Daniel Peter vendit sa fabrique à Gabriel Montet et fut nommé directeur de la Société des chocolats au lait Peter SA. Son entreprise chocolatière, devenue Peter-Cailler-Kohler SA en 1911, fusionna avec Nestlé en 1929.

Part of the extracted graph



Wissensextraktion:

vom LLM zu Linked Open Data


Vorteile

- Überprüfbar
- Nachvollziehbar
- Kombination «klassischer» NLP-Tools mit LLMs
- LOD gemäss einer bestimmten Ontologie

Nachteil

- Hoher Modellierungsaufwand

Fallbeispiel: Seminar zu LLMs (Basel/Bern)



Beheim: Buch von den Wienern

- Entity Extraction
- Normalization
- Norm-/Reference-Data Linking

Phase 4: Abgleich mit Karajan-Register und Versuch mit Normdatenbanken

In der letzten Phase wurden die normierten Namen noch mit dem bereits in der Karajan-Edition befindlichen Register abgeglichen. Verwendet wurde dafür eine leicht abgeänderte Version des Register-Promptes aus Phase 3. Von den ursprünglich 1.073 Namen konnten 1.056 mögliche Übereinstimmungen gefunden werden. Kleine Widersprüche wie veränderte Schreibweisen oder neue Informationen wurden wieder automatisch markiert und manuell behoben.

Weniger erfolgreich war der Abgleich über *OpenRefine* mit ausgewählten Normdatenbanken: GND (Gemeinsame Normdatei), WikiData oder VIAF (Virtual Authority File). Obwohl die Normierung der Namen und die Ergänzung der Kontextinformationen (Beruf, Amt, soziale Herkunft, etc.) die Ergebnisse verbesserte, konnte die Suche nicht auf den notwendigen Zeitraum eingeschränkt werden. Damit sind die gesuchten Personen zwar oft unter den Ergebnissen, müssen aber manuell bestätigt werden. Ein Versuch, die Datenbanken mittels LLMs zu durchsuchen, scheiterte an der Halluzination der Identifikationsnummern.

bern



Fallbeispiel:

Seminar zu LLMs (Basel/Bern)

Rahmenbedingungen:

rechtliche Fragen

Gratis = du bzw. deine Daten sind das Produkt (und werden genutzt)

Unterscheiden zwischen

- Personendaten (Schutzpflicht) → schwierig
- Urheberrechtlich geschütztem Material → lokale oder Uni-Modelle

Vorgaben der Uni Bern (unibe.ai):

- keine personenbezogenen Daten, keine Amts-/Berufsgeheimnisse
- gilt auch für die von der Uni lizenzierten Dienste

KI-Angebote der Universität Bern

Informatikdienste (unibe.ai)

GitHub Copilot
Microsoft Foundry (Forschung)
Adobe Firefly
DeepL Pro / Write Pro

Eigene Infrastruktur


GPUSack: gpustack.unibe.ch (Uni-
Netz)
Text Lab on OnDemand (Data
Science Lab)

Universitätsbibliothek

KI im wissenschaftlichen Arbeiten
Tool-Liste, Kurse, Beratung
ILIAS-Modul «KI-Sprachwerkzeuge
im Studium»

GPUStack

Open-Source-Modelle der Uni Bern



- gpustack.unibe.ch – im Uni-Netz (eduroam genügt)
- LLMs, multimodale Modelle, OCR, Spracherkennung, Embeddings
- Weboberfläche (Playground) und OpenAI-kompatible API
- Status «Ready» zeigt, was gerade läuft

GPUStack nutzen

Playground, API, Msty

- Mit eduroam der Universität verbinden
- gpustack.unibe.ch öffnen, anmelden, Modelle im Playground testen
- Access Control → API Keys: eigenen Schlüssel erzeugen (wird nur einmal angezeigt)
- Optional: In Msty Studio (msty.ai) oder Python als OpenAI-kompatiblen Anbieter eintragen

Verbindung

Base URL: <https://gpustack.unibe.ch/v1>

API Key: dein eigener Schlüssel

Modell: z. B. gpt-oss-120b

Achtung

API-Schlüssel sind persönlich: nicht auf Folien, in geteilte Dokumente oder Repositorien.

Toolübersicht

für die Aufgaben

NotebookLM

Eigener Chatbot mit eigenen
Anweisungen und Dokumenten

Recherche-Tools

KI-gestützte Literatursuche – Tool-
Liste der UB

Topic Modeling

Themen in Textmengen:
statistisch (Voyant) vs. LLM

Bildanalyse

Teachable Machine;
Bildbeschreibung mit Qwen3-VL

GPUStack

Open-Source-Modelle der Uni
Bern (eduroam)

Msty Studio

Lokale und entfernte Modelle in
einer App

Pause

14:50–15:05

- Zeit für Fragen und Unklarheiten
- WLAN- und Login-Probleme lösen
- Gruppen bilden (3–4 Personen)

Vom Wissen zur Aufgabe

Wofür würdest du generative KI einsetzen?

- Aufgabe definieren: Was soll das System mit welchem Material tun?
- Qualitätsanspruch festlegen: Wann ist es «gut genug»?
- Umsetzen: mit GPUStack – zum Vergleich gern kommerziell
- Evaluieren: Stichproben, Fehler sammeln, Systeme vergleichen

Konsequenzen für die eigene Arbeit mitdenken

Aufgaben zur Auswahl

15:05–16:05 · oder ein eigener Anwendungsfall

A • Chatbot mit NotebookLM

Fragen an eigene Dokumente (Reglemente, FAQ, Handbücher)
Google-Konto nötig · nur öffentliche Dokumente ohne Personendaten

B • Verschlagwortung & Extraktion

GPUStack (gpt-oss-120b): Schlagwörter aus vorgegebener Liste (GND), Personen/Orte/Daten in Tabelle
Fehlerquote in 20 Einträgen?

C • Historische Fotos

GPUStack (Qwen3-VL): Bilder aus E-Pics (ETH-Bibliothek) beschreiben
Abgleich mit den Archiv-Metadaten

D • OCR, Übersetzung, Regest

GPUStack: olmocr vs. qwen3-vl-8b
Scan → Text → Normalisierung → Zusammenfassung

Präsentation

16:05–16:35 · 5 Minuten pro Gruppe

- Aufgabe und Material
- Eingesetzte Systeme (kommerziell / lokal / Uni)
- Ergebnis – ein gelungenes und ein misslungenes Beispiel
- Grenzen: Was würdest du im Arbeitsalltag nicht der KI überlassen?

LLM, Bot, Agent

eine Arbeitsunterscheidung

LLM

Erzeugt auf Basis von Wahrscheinlichkeiten Text (zunehmend auch Bild, Ton, Code).
Setzt Muster fort – «weiss» nichts.

gpt-oss, Gemini, Claude, Llama

Bot

Anwendung um ein LLM: feste Anweisungen, eigene Dokumente (RAG).
Der Mensch löst jeden Schritt aus.

eigener GPT, NotebookLM, Swiss History Bot

Agent

Zerlegt ein Ziel in Schritte und nutzt selbständig Werkzeuge: Dateien, Web, Code, andere Agenten – auch zeitgesteuert.

Claude Code, Codex, OpenClaw, Agentic Historian

Leitfrage: Wer kontrolliert welchen Schritt – und was sieht der Anbieter dabei?

Model Context Protocol

Agentic Level 1: der Bot läuft auf dem System

- Standardisierte Kommunikation mit Dokumenten und Programmen
- Umsetzung in Cursor, Codex, Claude mit Zugriff auf Dateisysteme (eigener Computer, Server, ...)

Konsequenzen

- Direkte Umsetzung in Dateien und Git-Repositories
- Kontext über geteilte Dateien
- Rasche Umsetzung (= Effizienz?)
- Kontrollverlust – v. a. wenn Dokumente direkt geteilt werden

Die Daten werden an das Modell (= den Anbieter) gesendet!

Agent baut Website auf Zuruf

Experiment ohne Eingriff in Code und Inhalt

```
Get me an aspect on a topic before proposing anything concrete.
Good picture of the full scope. Let me write out the plan with a diagram before asking for permission.
Now the visualization diagram:
Here's the plan — please review before I run anything:
...

Plan: DH Intro Lecture Series — 6 Workstreams

Phase 1 — Infrastructure (prerequisite, ~1-2h)
thodel/intro-lecture becomes a git submodule inside dhhern/dhhern.github.io. No content duplication — source lives in one place, the Quarto
site references it. A GitHub Actions workflow auto-rebuilds when you push to intro-lecture. The subpage lives at dhhern.github.io/intro-
lecture/ and is not added to the main navbar.

Phase 2 — Lecturer bios (parallel, ~30 min)
For all IT lecturers: web search + 3-5 sentence bio, profile photo, ORCID badge, homepage link. AI-generated from public profiles, embedded on each
lecture page.

Phase 3 — Zotero (parallel, ~45 min)
New collection "Lecture-introduction" in dhh.unibe. 5 publications per lecturer chosen for relevance to their lecture topic via
OpenAlex/SemanticScholar. 17 x 5 = 85 entries.

Phase 4 — 80 Exam questions (parallel, ~1h)
Gemini 2.5 Pro reads each transcript + generates 40 single-correct + 40 multi-correct MC questions, distributed across 16 lectures (Course 9/Fomaro
excluded per program). Output as JSON + markdown for your review.

Phase 5 — Quiz platform (needs Phase 4)
Self-hosted Kahoot-style quiz at dhhern.github.io/intro-lecture/quiz/ — no login required, topic filter, 30s timer, instant feedback. All 80
questions embedded as static JSON. Optionally also exported as HSP for ILIAS.

Phase 6 — Podcast (independent, ~30 min)
Recommendation: NotebookLM — upload lecture overviews + generates natural 2-host podcast dialogue (~10 min), free, no scripting needed.
Alternative: Gemini script + ElevenLabs TTS for more control. Embedded as audio player on the landing page.
...

Visualization: https://github.com/thodel/intro-lecture/blob/main/docs/setup-visualization.html (open raw → save as HTML, or I can deploy it)
...

Five questions before I start:
1. Repo: Fork intro-lecture into the dhhern org, or keep at thodel/intro-lecture and reference as external submodule?
2. Quiz: Self-hosted HTML on the subpage (recommended) — also export to HSP for ILIAS?
3. Podcast: NotebookLM automated (10 min, no control) or scripted ElevenLabs (more control, more work)?
4. Bios: AI-generated from public profiles — do you want to review/edit before publishing, or publish directly?
5. Exam questions: Review all 80 in a Google Sheet / markdown file before I deploy the quiz?
```

- Virtuelle Ringvorlesung, basierend auf Aufzeichnungen
- Transkription, Zusammenfassungen
- Biografien der Dozierenden recherchieren
- Literaturrecherche als Update
- Quiz im Kahoot-Stil
- Iterative Erweiterung und Publikation

Plan → Freigabe → Subagenten → Fehler im Deployment

Agentic Coding: das Ergebnis

Digital Humanities — Introductions

FS 2026 · University of Bern · 3 ECTS

This page is not part of the main dhibern.github.io navigation. It is a companion resource for the lecture series **Digital Humanities — Introductions** (FS 2026). Bios on this page are AI-generated from public academic profiles and marked accordingly.


About the Series

The *Digital Humanities — Introductions* lecture series brings together 17 researchers from Swiss and European universities to present major research areas and methods in Digital Humanities. Lectures are fully online, can be worked through in any order, and are assessed via an open-book multiple-choice exam.

Exam: June 1, 2026 · 60 minutes · 20 randomly selected questions · 4 options each · no negative marking

Consultation: April 21 & May 27, 2026 · 12:15-14:00 · via Zoom/ILIAS


Thematic Overview



Agenten können übernehmen

OpenClaw als frühe Implementation

- Zugriff auf Dateisysteme (teils ganze Server), Mail, Kalender
- Kommunikation über Chat (Slack, Discord, WhatsApp, ...)
- «Skills» in Textform: Anweisungen für Datenzugriff und Verhalten
- Aktionen per Zeitplan (Cron-Jobs)
- Verknüpft mit Anbieter (API) oder selbst gehostetem LLM



Moltbook: NYT, 2.2.2026

Potenzielles Sicherheitsdesaster

Und nun ...

- Probleme bleiben → Überprüfung / Qualitätsmanagement
- Zusätzliche Herausforderungen bei der Sicherheit → klare Vorgaben, Bewusstsein für Probleme
- Abhängigkeit von Anbietern → eigene Lösungen implementieren
- Entwicklung unklar → offen bleiben

Ceterum censeo ...

denken wir nach über

- Was willst du mit den Daten erreichen?
- Qualität der Eingabe (z. B. Texterkennung)
 - Hyperkorrektur vs. falsche Erkennung
 - Extraktion funktioniert auch auf nicht perfekt erkanntem Text
- Open Source vs. Abhängigkeit von grossen Anbietern (aber einfache Umsetzung)
- Auswirkungen auf Gesellschaft und Umwelt
 - in beide Richtungen: Datenschutz, CO₂-Fussabdruck, ...

Gemeinsame Aufgabe:

Bibliotheken, Archive, Datenanbieter

- Kooperation
- Offene Publikation (Open Data)
- Offene Kommunikation: was funktioniert, was nicht
- [Digitalisierung]

→ Debatten über faire Nutzung nötig, v. a. mit kommerziellen Anbietern

Strategien für einen reflektierten Umgang

1 • Aufgabe vor Werkzeug

Ziel und
Qualitätsmassstab zuerst

2 • Daten klassifizieren

Personendaten &
Geschütztes nicht extern

3 • Stichproben

Fehlerquoten festhalten,
Quellen prüfen

4 • Nachvollziehbarkeit

Prompt, Modell, Datum
dokumentieren

5 • Mensch im Loop

Entscheide bleiben bei
Menschen

6 • Agenten eng führen

minimale Rechte, keine
Keys im Prompt

7 • Transparenz


KI-Unterstützung
kennzeichnen

8 • Kooperieren

Daten und Erfahrungen
teilen

Agentic Historian

Multi-Agenten-System



github.com/thodel/agentic-historian • alle Zwischenergebnisse als Markdown/JSON

Agentic Historian:

was daran lehrreich ist

- Historiker:in im Loop: Der Knowledge Hub steuert Klassifikation und Verknüpfung
- Prüfbarkeit: jeder Zwischenschritt liegt als Datei vor
- Kosten und Ressourcen werden von einem eigenen Agenten überwacht
- Austauschbar: jeder Agent kann jederzeit umgestellt werden (bspw. update von Modellen)
- Aber: Zugangsdaten, Tokens und Rechte müssen sauber getrennt bleiben

Evaluation

Link folgt

Vielen Dank!



dhbern.github.io/kritische-ki-nutzung

tobias.hodel@unibe.ch